1차 보고서

생성일	@2026년 3월 24일 오후 6:39

1. Team Info

1.1 과제명

CLIP-RD: Relational Distillation for Efficient CLIP Knowledge Distillation

1.2 팀 정보

06팀 브라우니

Github: https://github.com/Rosieyang01/CLIP-RD

1.3 팀 구성원

팀	이름	학번	이메일	역할
리더	정진이	2031054	cjeannie@ewhain.net	발표, 계획 수립, 자료 제작
팀원	장한나	2129032	hanna2129032@i.ewha.ac.kr	발표, 면담 진행, 실험 설계
팀원	양인경	2276188	2276188@i.ewha.ac.kr	발표, 실험 진행, 서버 세팅

2. Project-Summary

2.1 문제 정의

CLIP은 4억 개의 이미지-텍스트 쌍을 대조 학습으로 훈련한 대표적인 비전-언어 모델로, 객체 탐지 및 시각적 질의응답 등 다양한 태스크에서 강력한 성능을 보인다. 그러나 대규모 아키텍처 특성상 높은 메모리와 연산 자원을 요구하며, 이로 인해 경량화된 대안 모델에 대한 필요성이 대두되고 있다.

이를 해결하기 위한 접근법으로 지식 증류(Knowledge Distillation)가 주목받고 있다. 지식 증류는 대형 교사 모델의 지식을 소형 학생 모델로 전달하여, 적은 파라미터로도 유사한 성능을 달성하는 모델 압축 기법이다. 그러나 CLIP에 이를 적용하는 것은 단순한 분류 태스크와 달리, 이미지-텍스트 간의 특징과 관계 구조를 동시에 전달해야 하므로 난이도가 높다.

기존 연구들은 이 문제를 다양한 방식으로 해결하고자 했으나 명확한 한계를 지닌다. 특히 대표적인 사전연구인 CLIP-KD는 아키텍처 제약을 극복하고 ImageNet 제로샷에서 최고 성능을 달성했으나, 핵심 구성요소인 CRD(수평적 관계 증류, HRD)가 단방향 관계 정렬에만 의존하여 학생 모델의 표현 공간을 충분히 정렬하지 못하는 한계가 있다. 본 연구에서는 이러한 단방향 관계 증류의 한계를 핵심 문제로 정의하고, 이를 극복하기 위한 CLIP-RD를 제안한다.

2.2 기존 연구와의 비교

2.2.1 Knowledge Distillation

최근 대규모 모델의 발전은 다양한 작업에서 전례 없는 성능 향상을 이루었으며, 이는 주로 파라미터 수, 데이터셋 크기, 계산 자원이 증가할수록 모델 성능이 향상된다는 스케일링 법칙에 의해 설명된다. 그러나 이러한 발전에도 불

구하고, 높은 지연(latency)과 막대한 자원 요구는 모델 효율성을 개선하려는 연구를 활발하게 만들고 있다. 이러한 연구는 다양한 작업과 모달리티 전반에 걸쳐 진행되고 있다.

이러한 맥락에서, 지식 증류(Knowledge Distillation, KD)는 핵심적인 방법론으로 자리 잡았다. KD는 고용량의 teacher 모델이 학습한 풍부한 표현을 더 작은 student 모델로 전달함으로써, 제한된 구조를 가진 student가 더 높은 성능을 달성할 수 있도록 한다.

초기 KD는 단일 모달 모델을 중심으로 발전해왔으나, 최근에는 이러한 방법들이 Vision-Language Model(VLM)로 확장되고 있다. 본 연구에서는 멀티모달 증류 과정에서 관계적 구조에 대한 탐구가 부족하다는 점에 주목하며, 모달 간 관계를 보존하는 지식 전달 방식에 초점을 맞춘다.

2.2.2 Vision Language Model

CLIP은 OpenAI에 의해 제안된 Vision-Language Model(VLM)로, contrastive learning을 통해 풍부한 표현을 학습하도록 설계되었다. CLIP의 핵심 목적은 대칭적인 contrastive alignment loss를 최적화하는 것으로, 이는 짝을 이루는 이미지-텍스트 샘플의 임베딩은 가깝게 만들고, 짝이 아닌 샘플은 공통 임베딩 공간에서 멀어지도록 한다. 이러한 정렬 방식은 다양한 downstream task에서 강력한 zero-shot 일반화 성능을 가능하게 하며, 이미지 분류 및 크로스 모달 검색과 같은 작업에서 기존 VLM들을 능가하는 성능을 보이기도 한다.

효율적인 VLM에 대한 수요가 증가함에 따라, KD는 대규모로 사전 학습된 CLIP 모델을 압축하는 데 널리 사용되고 있다. 이러한 맥락에서, 기존 대부분의 방법들은 이미지-텍스트 쌍 및 teacher-student 임베딩 간의 관계 구조를 보존하기보다는, 주로 feature 수준의 표현을 증류하는 데 집중하고 있다. 이러한 점에 착안하여, 본 연구에서는 intra-modal 및 inter-modal 관계를 보존하기 위한 두 가지 증류 전략을 제안한다.

2.2.3 CLIP-KD

Vision-Language Model을 압축하는 데 있어 주목할 만한 발전 중 하나는 CLIP-KD로, feature, relation, gradient, contrastive 패러다임을 통합한 포괄적인 프레임워크를 제안한다. 단일 목적 함수에 의존하기보다는, CLIP-KD는 다양한 증류 전략들의 효과적인 조합을 경험적으로 도출한다. 그러나 여전히 relational distillation을 충분히 포착하지는 못한다. 이러한 견고한 프레임워크를 기반으로, 우리는 relational alignment의 정밀도를 강화함으로써 기존 방법을 넘어선 성능을 달성하고자 한다. 우리의 방법론은 이러한 기반을 확장하여, 임베딩 간의 복잡한 관계를 보다 정밀하게 증류할 수 있도록 한다.

2.2.4 TinyCLIP

TinyCLIP은 CLIP 프레임워크를 압축하기 위한 멀티모달 지식 증류의 초기 연구 중 하나이다. 이는 주로 분포 수준의 매칭을 통해, 이미지-텍스트 유사도 공간에서 teacher의 cross-modal alignment를 student가 모방하도록 유도한다. 또한 TinyCLIP은 weight inheritance와 multi-stage distillation 전략을 활용한다. 그러나 이 프레임워크는 대체로 teacher와 student 모델 간의 구조적 호환성에 크게 의존한다. 이에 반해, 우리의 방법은 relational alignment에 명시적으로 초점을 맞추며, 여러 벤치마크에서 일관되게 더 강력한 zero-shot 성능을 달성한다.

2.3 제안 내용

본 연구에서는 기존 단방향 관계 증류의 한계를 극복하기 위해, 교사-학생 간 관계 구조 및 모달리티 간 관계 구조를 핵심 증류 지식으로 정의하고, 이를 효과적으로 포착·전달하는 두 가지 새로운 기법을 제안한다.

- **VRD (Vertical Relational Distillation, 수직적 관계 증류)**: 교사와 학생 임베딩 간의 수직 방향 유사도 분포를 정렬한다. 대조 손실(contrastive loss)로 교사-학생 임베딩 간 유사도를 최대화하고, KL-발산 손실(KL-divergence loss)로 모달리티 전반에 걸친 분포 수준의 일관성을 강제한다.
- **XRD (Cross Relational Distillation, 교차 관계 증류)**: 교사 텍스트-학생 이미지, 교사 이미지-학생 텍스트 쌍을 구성하여 교차 방향 유사도 분포를 정렬한다. KL-발산을 최소화함으로써 교차 모달 교사-학생 유사도 분포의 양방향 대칭성을 강제한다.

위 두 기법을 통해 기존의 HRD(수평적 관계 증류)와 위 두 전략을 결합함으로써, 수평·수직·교차의 세 방향을 아우르는 다방향 관계 분포 모델링이 가능해진다. 이를 통해 학생 모델의 표현 공간을 효과적으로 정렬하고, CLIP의 강력한 일반화 능력을 학생 모델에 성공적으로 전달한다.

2.4 기대 효과 및 의의 > Experiments

제안된 기법을 활용한 실험 결과, 기존 기법 대비 ImageNet 제로샷 분류 성능을 0.8%p 향상시켰으며, 이를 통해 다방향 관계 증류 프레임워크의 효과성을 입증하였다. 이러한 결과는 본 기법이 CLIP의 범용성 향상에 기여할 수 있음을 시사한다.

CLIP-RD의 강건성을 검증하기 위해 두 가지 학생 네트워크에 대한 증류 실험을 수행하였으며, 제로샷 분류 및 검색 태스크 모두에서 성능을 평가하였다.

2.4.1 제로샷 분류 성능 확인

CLIP-RD의 ImageNet 제로샷 분류 성능을 평가한다. 학생 아키텍처로 ViT-T/16을 사용하며, TinyCLIP 및 CLIP-KD와 비교 실험을 수행한다. TinyCLIP의 성능은 CLIP-KD 논문에서 보고된 결과를 인용하였다. 또한 TinyCLIP의 학습에 사용된 데이터는 CLIP-KD 및 CLIP-RD의 학습 데이터보다 약 270만 개의 이미지-텍스트 쌍이 많음을 유의해야 한다. CLIP-KD는 공식 구현체를 사용하여 재현하였으며, 해당 결과는 별표(*)로 표기한다.

CLIP-RD는 42.1%의 정확도를 달성하여 ViT-T/16 베이스라인 대비 12.8%p 향상된 성능을 보인다. 또한 TinyCLIP 대비 1.3%p, CLIP-KD 대비 0.8%p 높은 성능을 달성한다. 이러한 결과는 다방향 관계 증류 프레임워크가 학생 모델의 표현 공간 정렬을 효과적으로 극대화하여 ImageNet 제로샷 분류 성능 향상으로 이어짐을 입증한다.

추가적으로 ImageNet 변형 데이터셋에 대한 평가에서도 CLIP-RD는 모든 데이터셋에서 CLIP-KD 대비 0.7%p~2.0%p 일관되게 높은 성능을 달성하였다. 이는 본 방법이 교사 모델로부터 학생 모델로 CLIP의 강력한 일반화 능력을 효과적으로 전달함을 보여준다.

Method	IN-1K	MSCOCO		Flickr	
		I2T	T2I	I2T	T2I
T: ViT-B/16	67.1	39.5	36.5	76.5	75.5
S: ViT-T/16	29.3	18.2	17.9	39.3	42.0
TinyCLIP	40.8	26.8	24.7	**58.6**	58.5
CLIP-KD*	41.3	27.4	24.1	58.4	56.4
CLIP-RD (Ours)	**42.1**	**27.8**	**25.1**	58.3	**58.6**

Table 1. Comparison with existing CLIP distillation methods. A star(*) denote sresults reproduced using the official implementation.

2.4.2 제로샷 교차 검색 성능 확인

ViT-B/16을 교사 모델로 사용한 결과, 학생 모델의 제로샷 교차 모달 검색 성능이 향상되었다. MSCOCO에서 CLIP-RD는 I2T 검색 R@1 기준으로 ViT-T/16 베이스라인 대비 9.6%p, TinyCLIP 대비 1.0%p 향상된 성능을 달성한다. 또한 CLIP-KD 대비 0.4%p 추가 향상되었으며, T2I 검색에서도 CLIP-KD 대비 1.0%p 높은 성능을 보인다.
Flickr에서도 유사한 경향이 나타나며, CLIP-RD는 CLIP-KD 대비 T2I 검색에서 2.2%p 향상된 성능을 달성한다. 이러한 결과는 본 프레임워크가 제로샷 교차 모달 검색 성능 향상에 효과적임을 입증한다.
또한 I2T 검색 R@1에서 CLIP-KD 대비 0.4%p, T2I 검색 R@1에서 0.6%p 높은 성능을 달성한다.

Method	IN-1K	IN-V2	IN-R	IN-S	CC3M	
					I2T	T2I
T: ViT-B/16	67.1	59.6	77.9	52.4	42.8	42.2
S: ViT-T/16	29.3	24.9	34.2	16.9	33.6	34.0
CLIP-KD	41.3	35.5	46.3	26.3	40.2	38.7
CLIP-RD (Ours)	**42.1**	**36.2**	**48.3**	**27.3**	**40.6**	**39.3**

Table 2. Zero-shot classification and retrieval performance comparison.

2.4.3 다양한 데이터셋에서의 제로샷 분류 성능 확인

Method	IN	CIFAR-10	CIFAR-100	EuroSAT	Food101	RESISC45	Sun397	Caltech101
T: ViT-B/16	67.1	91.1	71.3	33.8	80.2	57.8	69.0	87.0
S: ViT-T/16	29.3	66.9	27.5	11.6	27.8	24.4	38.1	66.2
CLIP-KD	41.3	74.2	39.9	18.0	41.6	**32.6**	51.6	75.9
CLIP-RD (Ours)	**42.1**	**75.5**	**42.3**	**25.5**	**43.2**	**32.6**	**52.0**	**78.0**

Table 3. Zero-shot classification accuracy on various datasets.

우리는 다양한 데이터셋에 대해 zero-shot 이미지 분류 성능을 평가하여 모델의 강건성을 검증한다. 구체적으로, CLIP의 zero-shot 성능 평가에 사용되었던 8개의 데이터셋을 선택하였다. 우리는 student baseline, CLIP-KD, 그리고 제안하는 CLIP-RD를 비교한다. 표 3에서 볼 수 있듯이, 제안하는 CLIP-RD는 모든 데이터셋에서 CLIP-KD 대비 최대 7.5%p까지 성능 향상을 보인다.

CIFAR-10/100, Caltech101과 같은 객체 분류 벤치마크에서는 CLIP-KD 대비 1.3%p에서 2.4%p의 성능 향상을 기록한다. 특히, 난이도가 높은 위성 이미지 데이터셋인 EuroSAT에서는 CLIP-RD가 7.5%p의 큰 성능 향상을 보인다. 또한, fine-grained 분류 데이터셋인 Food101에서는 1.6%p의 성능 향상을 달성하였다. 더불어, 장면 이해 벤치마크인 Sun397에서도 CLIP-KD 대비 0.4%p의 성능 향상을 보인다. 이러한 결과는 우리 모델이 강력한 성능을 제공함을 보여준다.

2.5 주요 기능 리스트

2.5.1 전체 개요

이 절에서는 두 가지 새로운 증류 전략인 VRD와 XRD로 구성된 CLIP-RD 프레임워크를 제안한다. teacher의 이미지 임베딩을 v_k^T, student를 v_k^S로 정의하고, 텍스트 임베딩은 각각 s_k^T, s_k^S로 정의한다. 미니배치 $\mathcal{B} = (I_k, T_k)_{k=1}^{|\mathcal{B}|}$가 주어졌을 때, 임베딩 간 relational distribution을 계산한다.

2.5.2 CLIP 기본 구조

CLIP은 contrastive learning을 통해 이미지와 텍스트를 공동 임베딩 공간에 정렬한다.

- **Image → Text Loss**

  $$\mathcal{L}_{I \to T} = -\log \frac{\exp(v_k \cdot s_k / \tau)}{\sum_{b=1}^{|\mathcal{B}|} \exp(v_k \cdot s_b / \tau)}$$

- **Text → Image Loss**

  $$\mathcal{L}_{T \to I} = -\log \frac{\exp(s_k \cdot v_k / \tau)}{\sum_{b=1}^{|\mathcal{B}|} \exp(s_k \cdot v_b / \tau)}$$

- **최종 CLIP loss**

  $$\mathcal{L}_{task} = \frac{1}{2}(\mathcal{L}_{I \to T} + \mathcal{L}_{T \to I})$$

2.5.3 CLIP 기반 Loss

(1) Feature Distillation (FD)

Feature Distillation은 teacher와 student의 동일 모달리티 내 feature embedding을 직접 정렬하는 가장 기본적인 증류 방식이다. 즉, 이미지 임베딩은 이미지 임베딩끼리, 텍스트 임베딩은 텍스트 임베딩끼리 맞추도록 학습한다. 이 방식은 teacher의 표현을 student가 그대로 모방하도록 유도하지만, 샘플 간 관계 구조보다는 개별 feature 값 자체에 집중한다는 특징이 있다.

$$\mathcal{L}_{FD} = \frac{1}{|\mathcal{B}|}\sum_{k=1}^{|\mathcal{B}|}(\|v_k^T - v_k^S\|_2^2 + \|s_k^T - s_k^S\|_2^2)$$

(2) Interactive Contrastive Learning (ICL)

- Image → Text

  $$\mathcal{L}_{ICL,I\to T} = -\log \frac{\exp(v_k^S \cdot s_k^T/\tau)}{\sum_{b=1}^{|\mathcal{B}|}\exp(v_k^S \cdot s_b^T/\tau)}$$

- Text → Image

  $$\mathcal{L}_{ICL,T\to I} = -\log \frac{\exp(s_k^S \cdot v_k^T/\tau)}{\sum_{b=1}^{|\mathcal{B}|}\exp(s_k^S \cdot v_b^T/\tau)}$$

- 최종 ICL

  $$\mathcal{L}_{ICL} = \frac{1}{2}(\mathcal{L}_{ICL,I\to T} + \mathcal{L}_{ICL,T\to I})$$

(3) Horizontal Relational Distillation (HRD)

HRD는 수평 방향의 관계 구조를 student에게 전달한다. 즉, 하나의 anchor(이미지 또는 텍스트)를 기준으로 batch 내 다른 샘플들과의 유사도 분포를 정렬한다. 이를 통해 student는 teacher가 가진 구조화된 semantic 관계를 학습하게 된다.

- 확률 분포 정의

  $$p_k^T[j] = \frac{\exp(v_k^T \cdot s_j^T/\tau^T)}{\sum_{b=1}^{|\mathcal{B}|}\exp(v_k^T \cdot s_b^T/\tau^T)}$$

  $$p_k^S[j] = \frac{\exp(v_k^S \cdot s_j^S/\tau^S)}{\sum_{b=1}^{|\mathcal{B}|}\exp(v_k^S \cdot s_b^S/\tau^S)}$$

  $$q_k^T[j] = \frac{\exp(s_k^T \cdot v_j^T/\tau^T)}{\sum_{b=1}^{|\mathcal{B}|}\exp(s_k^T \cdot v_b^T/\tau^T)}$$

  $$q_k^S[j] = \frac{\exp(s_k^S \cdot v_j^S/\tau^S)}{\sum_{b=1}^{|\mathcal{B}|}\exp(s_k^S \cdot v_b^S/\tau^S)}$$

  p_k^M는 v_k를 anchor로 하여 batch 내 모든 s_j와의 유사도를 기반으로 계산된 확률 분포이며, q_k^M는 s_k를 anchor로 하여 batch 내 모든 v_j와의 유사도를 기반으로 계산된 확률 분포이다.

- HRD loss

  $$\mathcal{L}_{HRD,I\to T} = \frac{1}{|\mathcal{B}|}\sum_{k=1}^{|\mathcal{B}|}\sum_{j=1}^{|\mathcal{B}|} p_k^T[j]\log\frac{p_k^T[j]}{p_k^S[j]}$$

  $$\mathcal{L}_{HRD,T\to I} = \frac{1}{|\mathcal{B}|}\sum_{k=1}^{|\mathcal{B}|}\sum_{j=1}^{|\mathcal{B}|} q_k^T[j]\log\frac{q_k^T[j]}{q_k^S[j]}$$

  $$\mathcal{L}_{HRD} = \mathcal{L}_{HRD,I\to T} + \mathcal{L}_{HRD,T\to I}$$

  KL divergence를 통해 student는 teacher의 수평적 relational structure를 효과적으로 모방한다. 이를 통해 더 구조화된 semantic 관계를 학습하게 된다.

  HRD를 이후 섹션에서 소개되는 VRD 및 XRD와 결합함으로써, CLIP-RD는 다방향 relational dependency를 명시적으로 모델링할 수 있다.

2.5.3 Vertical Relational Distillation (VRD)

VRD는 모달리티 간 distillation 강도의 일관성을 분포 수준에서 강제하는 방법이다. 이는 image–image 및 text–text 간의 수직 방향 유사도 분포를 활용한다. teacher와 student를 각각 anchor로 사용하여 분포를 구성하며, 각 모달리티에 대해 학습 가능한 temperature를 사용한다.

- Intra-modality distribution

$$I_k^{TS}[j] = \frac{\exp(v_k^T \cdot v_j^S / \tau^i)}{\sum_{b=1}^{|\mathcal{B}|} \exp(v_k^T \cdot v_b^S / \tau^i)}$$

$$I_k^{ST}[j] = \frac{\exp(v_k^S \cdot v_j^T / \tau^i)}{\sum_{b=1}^{|\mathcal{B}|} \exp(v_k^S \cdot v_b^T / \tau^i)}$$

$$T_k^{TS}[j] = \frac{\exp(s_k^T \cdot s_j^S / \tau^t)}{\sum_{b=1}^{|\mathcal{B}|} \exp(s_k^T \cdot s_b^S / \tau^t)}$$

$$T_k^{ST}[j] = \frac{\exp(s_k^S \cdot s_j^T / \tau^t)}{\sum_{b=1}^{|\mathcal{B}|} \exp(s_k^S \cdot s_b^T / \tau^t)}$$

이러한 relational structure를 효과적으로 전달하기 위해, VRD는 서로 보완적인 두 가지 loss, 즉 contrastive loss와 KL-divergence loss로 구성된다. contrastive loss의 경우, 각 intra-modality 분포에 적용되는 InfoNCE 기반 목적 함수를 사용하며, 동일한 모달리티 내에서 teacher와 student 임베딩 간의 유사도를 최대화하도록 한다. 구체적으로, 이 loss는 각 모달리티에 대해 $\mathcal{L}_{CE-Image}$와 $\mathcal{L}_{CE-Text}$로 나누어 계산된다. $\mathcal{L}_{CE-Image}$의 경우, teacher와 student를 각각 anchor로 사용하는 두 개의 image–image 유사도 분포를 활용하며, 이로부터 얻어진 loss들을 합산한다. $\mathcal{L}_{CE-Text}$ 역시 동일한 방식으로 text–text 분포를 사용하여 계산된다.

최종적으로 $\mathcal{L}_{VRD-CE}$는 $\mathcal{L}_{CE-Image}$와 $\mathcal{L}_{CE-Text}$를 평균하여 얻어진다. 주어진 intra-modality 분포에 대해, $\mathcal{L}_{VRD-CE}$는 다음과 같이 정의된다.

- Cross-entropy loss

$$\mathcal{L}_{CE-Image} = -\log I_k^{TS}[k] - \log I_k^{ST}[k]$$

$$\mathcal{L}_{CE-Text} = -\log T_k^{TS}[k] - \log T_k^{ST}[k]$$

$$\mathcal{L}_{VRD-CE} = \frac{1}{2}(\mathcal{L}_{CE-Image} + \mathcal{L}_{CE-Text})$$

이후, 우리는 intra-modality 유사도 분포를 정렬하기 위해 KL-divergence loss를 적용한다. 이 loss는 이미지 유사도 분포가 텍스트 유사도 분포를 근사하도록 만든다. 이를 통해 모달리티 전반에 걸쳐 teacher와 student 간 distillation 강도의 일관성이 유지되도록 한다. 구체적으로, 이 loss는 teacher를 anchor로 하는 분포와 student를 anchor로 하는 분포 모두에 적용되며, 이들을 평균하여 $\mathcal{L}_{VRD-KL}$을 계산한다. 이는 다음과 같이 정의된다.

- KL divergence loss

$$\mathcal{L}_{VRD_TS} = \frac{1}{|\mathcal{B}|} \sum_{k=1}^{|\mathcal{B}|} \sum_{j=1}^{|\mathcal{B}|} I_k^{TS}[j] \log \frac{I_k^{TS}[j]}{T_k^{TS}[j]}$$

$$\mathcal{L}_{VRD_ST} = \frac{1}{|\mathcal{B}|} \sum_{k=1}^{|\mathcal{B}|} \sum_{j=1}^{|\mathcal{B}|} I_k^{ST}[j] \log \frac{I_k^{ST}[j]}{T_k^{ST}[j]}$$

$$\mathcal{L}_{VRD-KL} = \frac{1}{2}(\mathcal{L}_{VRD_TS} + \mathcal{L}_{VRD_ST})$$

전체 VRD loss는 $\mathcal{L}_{VRD-CE}$와 $\mathcal{L}_{VRD-KL}$의 합으로 정의된다. 이 두 가지 loss를 함께 최적화함으로써, VRD는 teacher 모델의 표현과 수직 방향으로 형성된 의존 관계를 student 모델로 효과적으로 전달한다.

- VRD total loss

$$\mathcal{L}_{VRD} = \mathcal{L}_{VRD-CE} + \mathcal{L}_{VRD-KL}$$

2.5.4 Cross Relational Distillation (XRD)

우리는 cross-modal relational knowledge를 효과적으로 전달하기 위해 새로운 distillation 방법인 Cross Relational Distillation(XRD)을 추가로 제안한다. XRD는 그림에 나타난 바와 같이, inter-modality 유사도 분포(image–text 및 text–image)를 정렬한다. 기존의 대부분의 distillation 방법들은 feature 수준 또는 intra-

modality 정렬에 집중해왔다. 그러나 우리의 방법은 teacher와 student의 이미지 및 텍스트 표현 간 양방향 관계를 포착한다.

구체적으로, XRD는 네 가지 pairwise 유사도 분포로 구성된다.

- $R_{T_i \to S_t}$: teacher 이미지에서 student 텍스트로의 pairwise 유사도 분포
- $R_{T_t \to S_i}$: teacher 텍스트에서 student 이미지로의 pairwise 유사도 분포
- $R_{S_i \to T_t}$: student 이미지에서 teacher 텍스트로의 pairwise 유사도 분포
- $R_{S_t \to T_i}$: student 텍스트에서 teacher 이미지로의 pairwise 유사도 분포

이미지 및 텍스트 임베딩과 학습 가능한 temperature 파라미터가 주어졌을 때, 각 유사도 분포는 다음과 같이 정의된다.

- cross-modal distribution

$$\mathcal{R}_k^{T_i \to S_t}[j] = \frac{\exp(v_k^T \cdot s_j^S / \tau)}{\sum_{b=1}^{|\mathcal{B}|} \exp(v_k^T \cdot s_b^S / \tau)}$$
$$\mathcal{R}_k^{T_t \to S_i}[j] = \frac{\exp(s_k^T \cdot v_j^S / \tau)}{\sum_{b=1}^{|\mathcal{B}|} \exp(s_k^T \cdot v_b^S / \tau)}$$
$$\mathcal{R}_k^{S_i \to T_t}[j] = \frac{\exp(v_k^S \cdot s_j^T / \tau)}{\sum_{b=1}^{|\mathcal{B}|} \exp(v_k^S \cdot s_b^T / \tau)}$$
$$\mathcal{R}_k^{S_t \to T_i}[j] = \frac{\exp(s_k^S \cdot v_j^T / \tau)}{\sum_{b=1}^{|\mathcal{B}|} \exp(s_k^S \cdot v_b^T / \tau)}$$

각 분포는 두 모달리티와 두 네트워크 간의 샘플 쌍 사이의 유사도를 나타낸다. XRD loss는 $\mathcal{L}_{T \to S}$와 $\mathcal{L}_{S \to T}$로 구성된다.

$\mathcal{L}_{T \to S}$는 *teacher에서 student로 향하는 방향의 분포들 간 KL-divergence를 최소화하며,* $\mathcal{L}_{S \to T}$는 student에서 teacher로 향하는 방향의 분포들 간 KL-divergence를 최소화한다.

VRD가 수직 방향의 분포를 정렬하는 것과 달리, XRD는 cross-modal dependency를 정렬하며, 이를 위해 양방향 모두에 KL-divergence를 적용하고 그 결과를 평균하여 대칭적인 정렬을 보장한다.

구체적으로,$\mathcal{L}_{T \to S}$는 $R_k^{T_i \to S_t}[j]$와 $R_k^{Tt \to S_i}[j]$ 간의 KL-divergence를 계산하여 얻어진다. $\mathcal{L}_{S \to T}$ 역시 student에서 teacher로 향하는 분포들에 동일한 방식으로 적용된다.

이러한 전략을 통해 student는 한 네트워크의 특정 모달리티가 다른 네트워크의 반대 모달리티와 어떻게 의미적으로 상호작용하는지를 학습하게 되며, 결과적으로 더 풍부한 cross-modal 정렬이 가능해진다.

$\mathcal{L}_{T \to S}$와 $\mathcal{L}_{S \to T}$의 수식은 다음과 같다.

- KL loss

$$\mathcal{L}_{T \to S} = \frac{1}{2}\left(\frac{1}{|\mathcal{B}|}\sum_{k=1}^{|\mathcal{B}|}\sum_{j=1}^{|\mathcal{B}|} \mathcal{R}_k^{T_i \to S_t}[j] \log \frac{\mathcal{R}_k^{T_i \to S_t}[j]}{\mathcal{R}_k^{T_t \to S_i}[j]} + \frac{1}{|\mathcal{B}|}\sum_{k=1}^{|\mathcal{B}|}\sum_{j=1}^{|\mathcal{B}|} \mathcal{R}_k^{T_t \to S_i}[j] \log \frac{\mathcal{R}_k^{T_t \to S_i}[j]}{\mathcal{R}_k^{T_i \to S_t}[j]}\right)$$
$$\mathcal{L}_{S \to T} = \frac{1}{2}\left(\frac{1}{|\mathcal{B}|}\sum_{k=1}^{|\mathcal{B}|}\sum_{j=1}^{|\mathcal{B}|} \mathcal{R}_k^{S_i \to T_t}[j] \log \frac{\mathcal{R}_k^{S_i \to T_t}[j]}{\mathcal{R}_k^{S_t \to T_i}[j]} + \frac{1}{|\mathcal{B}|}\sum_{k=1}^{|\mathcal{B}|}\sum_{j=1}^{|\mathcal{B}|} \mathcal{R}_k^{S_t \to T_i}[j] \log \frac{\mathcal{R}_k^{S_t \to T_i}[j]}{\mathcal{R}_k^{S_i \to T_t}[j]}\right)$$

전체 XRD loss인 $\mathcal{L}_{XRD}$는 $\mathcal{L}_{T \to S}$와$\mathcal{L}_{S \to T}$를 평균하여 정의되며, 다음과 같이 표현된다.

$$\mathcal{L}_{XRD} = \frac{1}{2}(\mathcal{L}_{T \to S} + \mathcal{L}_{S \to T})$$

이러한 대칭적 구성은 모달리티 전반에 걸쳐 teacher와 student 간 relational mapping의 양방향 일관성을 더욱 보장한다. 따라서 student 모델은 teacher가 포착한 cross-modal 구조적 지식을 학습할 수 있으며, 이를 통해 이미지와 텍스트 임베딩 간 의미적 정렬이 향상된다. 결과적으로, HRD, VRD, XRD는 함께 다방향 relational distillation 프레임워크를 구성하며, teacher에서 student로의 대칭적이고 균형 잡힌 지식 전달을 가능하게 한다.

2.5.5 CLIP-RD

우리의 프레임워크인 CLIP-RD는 다음과 같은 결합 loss 함수를 최소화하도록 학습된다.

- CLIP-RD total loss

$$\mathcal{L}_{CLIP-RD} = \mathcal{L}_{task} + \alpha\mathcal{L}_{FD} + \beta\mathcal{L}_{ICL} + \lambda\mathcal{L}_{RD}$$

여기서 $\mathcal{L}_{RD} \in \mathcal{L}_{HRD}, \mathcal{L}_{VRD}, \mathcal{L}_{XRD}$이다. α, β, λ는 서로 다른 loss 항들의 기여도를 조절하는 하이퍼파라미터이다. 모든 실험에서 우리는 $\alpha = 2000$, $\beta = 1$, $\lambda = 1$로 설정하였으며, 이는 기존 연구에서 보고된 $\mathcal{L}_{FD}, \mathcal{L}_{ICL}, \mathcal{L}_{HRD}$에 대한 최적의 스케일링 값을 따른 것이다. 이와 같은 프레임워크인 $\mathcal{L}_{CLIP-RD}$는 보다 강건한 student 모델을 위해 relational knowledge를 효과적으로 전달한다.

3. Project-Design

3.1 요구사항 정의

기존 CLIP-KD 기반 학생 모델은 다음과 같은 문제를 가진다.

첫째, 이미지-이미지 및 텍스트-텍스트 간 동일 모달리티 내부 관계(intra-modal relation)가 충분히 학습되지 않아 표현력에 한계가 존재한다.

둘째, 이미지-텍스트 간 교차 모달 관계(inter-modal relation)가 비대칭적으로 학습되어, 멀티모달 정렬 성능이 저하된다.

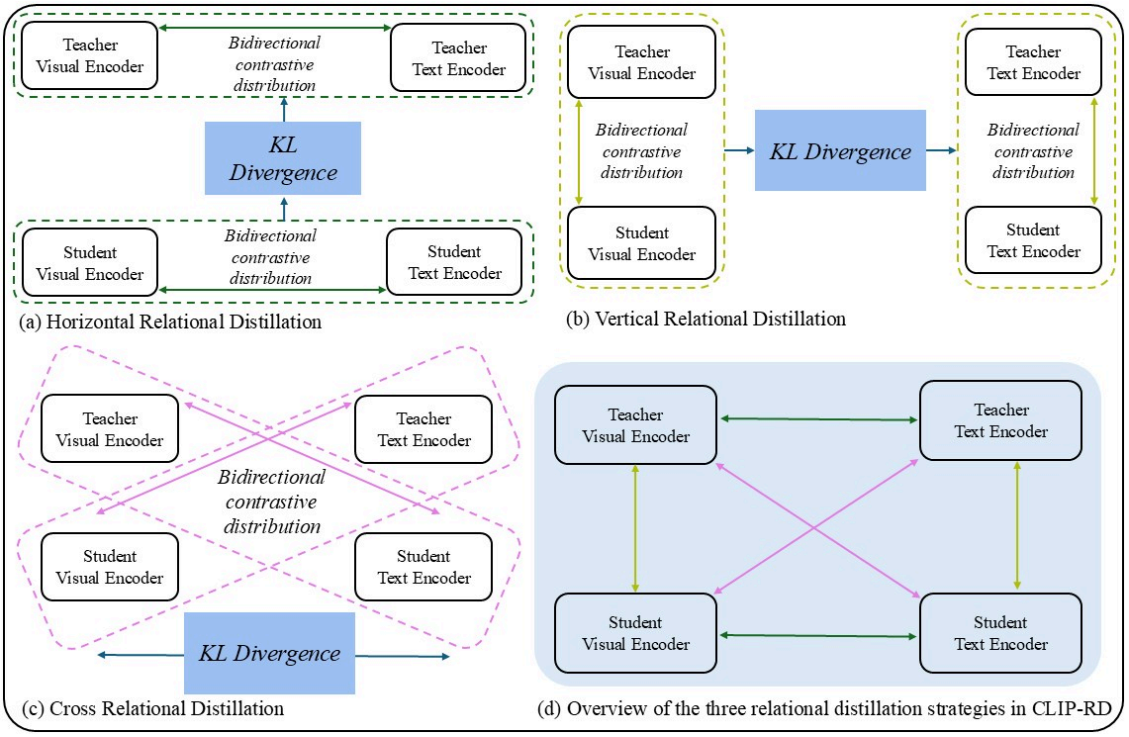
셋째, 결과적으로 이미지넷 분류(ImageNet classification), 크로스 모달 검색(cross-modal retrieval), 제로샷 성능(zero-shot performance)과 같은 다운스트림 태스크에서 성능 손실이 발생한다.

따라서, 본 발명이 해결하고자 하는 기술적 과제는 다음과 같다.

1. 기존 단일 방향 관계 증류 방식의 한계를 극복하고, 수평(horizontal), 수직(vertical), 교차(cross) 방향을 포함하는 다중 방향 관계를 통합적으로 학습할 수 있어야 한다.
2. 이미지-이미지, 텍스트-텍스트 간의 intra-modal 관계뿐 아니라 이미지-텍스트 간 inter-modal 관계를 양방향으로 정렬하여, 보다 정밀한 멀티모달 임베딩 공간을 형성해야 한다.
3. 교사와 학생 간 단순 feature 정렬을 넘어, 분포 수준에서 관계 일관성을 유지하도록 해야 한다.
4. 제안 방법(CLIP-RD)은 기존 CLIP-KD 대비 ImageNet classification, cross-modal retrieval, zero-shot generalization 성능 향상을 모두 만족해야 한다.
5. 제한된 파라미터를 가지는 student 모델에서도 teacher 모델의 표현 구조를 효과적으로 전달하여 성능 저하를 최소화하면서 효율성을 확보해야 한다.

결론적으로, 본 발명의 요구사항은 기존 CLIP-KD의 한계인 관계 정보의 불완전한 전달 문제를 해결하고, 다중 방향 관계 기반의 정교한 지식 증류를 통해 CLIP-KD 대비 우수한 성능을 달성하는 데 있다.

3.2 전체 시스템 구성



본 프레임워크인 CLIP-RD는 다음과 같은 결합 손실 함수를 최소화하여 학습됩니다: $\mathcal{L}_{\text{task}}$, $\mathcal{L}_{\text{FD}}$, $\mathcal{L}_{\text{ICL}}$, *수평 관계 증류 손실* $\mathcal{L}_{\text{HRD}}$, 제안된 수직 관계 증류 손실 $\mathcal{L}_{\text{VRD}}$, *그리고 교차 관계 증류 손실* $\mathcal{L}_{\text{XRD}}$. 전체 손실 함수는 다음과 같습니다. $\mathcal{L}_{\text{CLIP-RD}} = \mathcal{L}_{\text{task}} + \alpha\mathcal{L}_{\text{FD}} + \beta\mathcal{L}_{\text{ICL}} + \lambda\mathcal{L}_{\text{RD}}$

여기서 $\mathcal{L}_{\text{RD}} \in \{\mathcal{L}_{\text{HRD}}, \mathcal{L}_{\text{VRD}}, \mathcal{L}_{\text{XRD}}\}$. α, β, 및 λ는 서로 다른 손실 항의 기여도를 균형 있게 조절하는 하이퍼파라미터입니다. 모든 실험에서, 모든 관계형 증류 손실에 대해 $\alpha = 2000$, $\beta = 1$, 및 $\lambda = 1$로 설정했으며, 이는 CLIP-KD에 보고된 $\mathcal{L}_{\text{FD}}$, $\mathcal{L}_{\text{HRD}}$, $\mathcal{L}_{\text{ICL}}$ 에 대한 최적 스케일링 계수를 채택한 것입니다. 이 프레임워크인 $\mathcal{L}_{\text{CLIP-RD}}$는 더욱 견고한 학생 모델을 위한 관계형 지식을 제공합니다.